Практичне заняття №11

ЗМІ. Тема 6

Теорія ймовірностей та математична статистика

Тема роботи:

Кореляційний аналіз. Визначення типу та тісноти взаємозв’язку між випадковими змінними

Виконав: студент групи АІК-43
Вівчар Вадим

Мета роботи

Навчитись визначати тип та тісноту взаємозв’язку між випадковими змінними.

Основні задачі роботи

- Навчитися визначати метод кореляційного аналізу, необхідний для розрахунку взаємозв’язку між випадковими змінними.
- Розраховувати коефіцієнт кореляції та робити висновок про тип взаємозв’язку між змінними.

Теоретичні відомості

Кореляційний аналіз - це метод статистичного дослідження, який використовується для оцінювання залежності між двома або більше випадковими величинами. Основною метою кореляційного аналізу є визначення сили та напряму зв’язку між ознаками.

Коефіцієнт кореляції r змінюється в межах від -1 до 1. Додатне значення показує прямий зв’язок, від’ємне - зворотний зв’язок, а значення, близьке до нуля, свідчить про слабку або відсутню лінійну залежність.

Для кількісних нормально розподілених даних застосовують коефіцієнт кореляції Пірсона. Якщо дані не відповідають нормальному розподілу або є ранговими, використовують ранговий коефіцієнт кореляції Спірмена.

Коефіцієнт Спірмена обчислюється на основі рангів значень змінних. Його формула має вигляд: $r_s = 1 - 6\Sigma d^2 / (n(n^2 - 1))$, де d - різниця між рангами двох змінних, n - кількість спостережень.

Значення r	**Рівень зв’язку між змінними**
0,75 - 1,00	дуже високий позитивний
0,50 - 0,74	високий позитивний
0,25 - 0,49	середній позитивний
0,00 - 0,24	слабкий позитивний
0,00 - -0,24	слабкий негативний
-0,25 - -0,49	середній негативний
-0,50 - -0,74	високий негативний
-0,75 - -1,00	дуже високий негативний

Виконання завдання

Завдання практичного заняття: провести розрахунок коефіцієнта кореляції між змінними Lipoproteins та Hemoglobin.

Крок 1. Імпорт даних у PSPP

Файл із даними було імпортовано у програму PSPP. Для аналізу використовувалися змінні Lipoproteins та Hemoglobin. Змінна ID застосовувалася лише як номер спостереження та не брала участі в кореляційному аналізі.

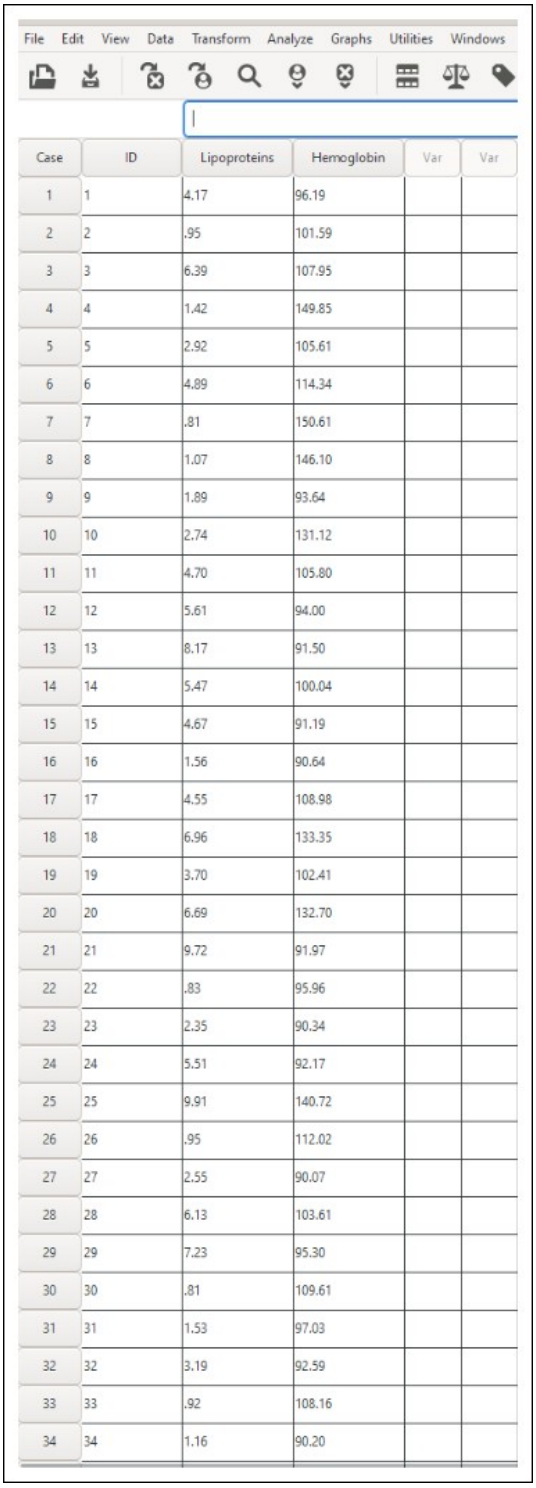

File Edit View Data Transform Analyze Graphs Utilities Windows

Case	ID	Lipoproteins	Hemoglobin	Var	Var
1	1	4.17	96.19		
2	2	.95	101.59		
3	3	6.39	107.95		
4	4	1.42	149.85		
5	5	2.92	105.61		
6	6	4.89	114.34		
7	7	.81	150.61		
8	8	1.07	146.10		
9	9	1.89	93.64		
10	10	2.74	131.12		
11	11	4.70	105.80		
12	12	5.61	94.00		
13	13	8.17	91.50		
14	14	5.47	100.04		
15	15	4.67	91.19		
16	16	1.56	90.64		
17	17	4.55	108.98		
18	18	6.96	133.35		
19	19	3.70	102.41		
20	20	6.69	132.70		
21	21	9.72	91.97		
22	22	.83	95.96		
23	23	2.35	90.34		
24	24	5.51	92.17		
25	25	9.91	140.72		
26	26	.95	112.02		
27	27	2.55	90.07		
28	28	6.13	103.61		
29	29	7.23	95.30		
30	30	.81	109.61		
31	31	1.53	97.03		
32	32	3.19	92.59		
33	33	.92	108.16		
34	34	1.16	90.20		

Рисунок 1 - Вхідні дані для кореляційного аналізу

Крок 2. Побудова діаграми розсіювання

Для попередньої оцінки залежності між змінними було побудовано діаграму розсіювання. На графіку кожна точка відповідає одному спостереженню з парою значень Lipoproteins та Hemoglobin.

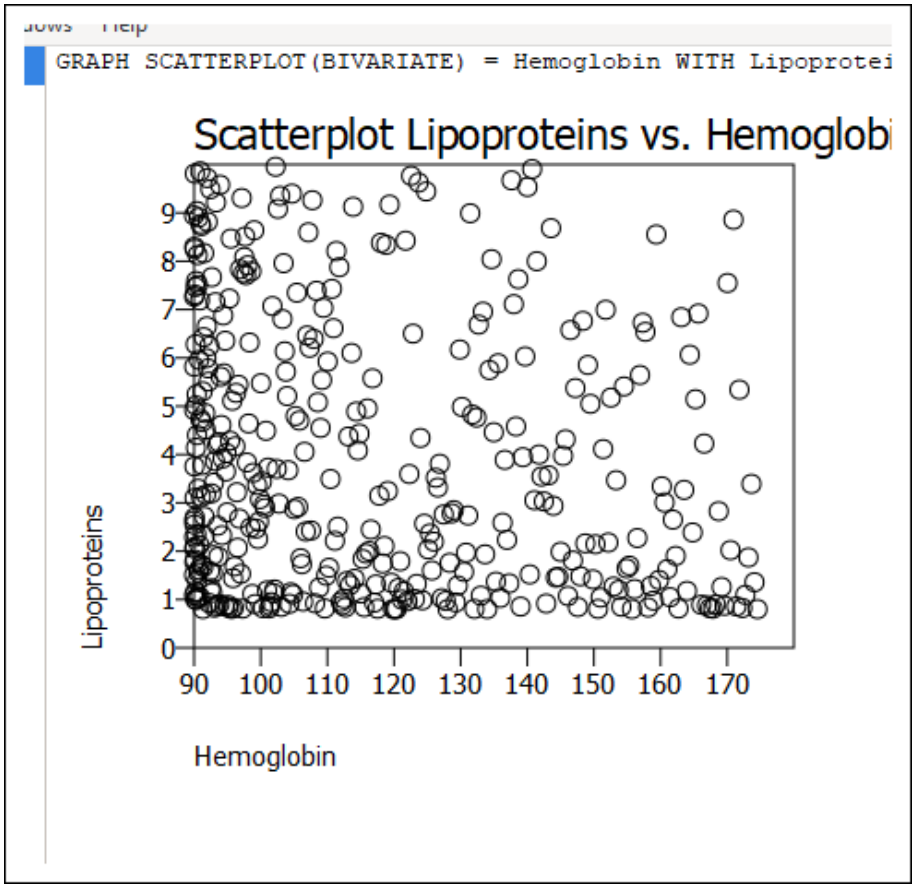

Рисунок 2 - Діаграма розсіювання між змінними Lipoproteins та Hemoglobin

За діаграмою розсіювання видно, що точки розміщені досить розсіяно, однак спостерігається слабка тенденція до зворотного зв’язку між змінними. Попередньо можна припустити наявність слабкої негативної залежності.

Крок 3. Перевірка нормальності розподілу

Перед вибором методу кореляційного аналізу було перевірено нормальність розподілу даних за критерієм Колмогорова-Смірнова. Нульова гіпотеза H0: дані мають нормальний розподіл. Альтернативна гіпотеза H1: дані не мають нормального розподілу.

```
NPAR TEST
        /KOLMOGOROV-SMIRNOV (NORMAL) =
```

One-Sample Kolmogorov-Smirnov Test

		ipoprotein	emoglobi
N		402	390
Normal Parameters	Mean	3.86	117.41
	Std. Deviation	2.74	25.19
Most Extreme Differences	Absolute	.13	.14
	Positive	.12	.13
	Negative	-.13	-.14
Kolmogorov-Smirnov Z		2.64	2.73
Asymp. Sig. (2-tailed)		.000	.000

Рисунок 3 - Перевірка нормальності розподілу даних за критерієм Колмогорова-Смірнова

За результатами тесту для обох змінних отримано Asymp. Sig. = 0,000. Оскільки $p < 0,05$, гіпотеза про нормальний розподіл відхиляється. Отже, для подальшого аналізу доцільно використовувати не коефіцієнт Пірсона, а коефіцієнт рангової кореляції Спірмена.

Крок 4. Розрахунок коефіцієнта кореляції Спірмена

У PSPP прямий розрахунок Спірмена в наявній версії був недоступний, тому коефіцієнт Спірмена було обчислено через рангові змінні. Для цього були створені ранги R_Lipoproteins та R_Hemoglobin, після чого розраховано кореляцію Пірсона між цими рангами. Такий підхід відповідає визначенню коефіцієнта Спірмена.

```
CORRELATION
        /VARIABLES =  R_Lipoproteins R
        /PRINT = TWOTAIL NOSIG.
```

Correlations

		Lipoprotei	Hemoglob
R_Lipoproteins	Pearson Correlation	1.000	-.192[a]
	Sig. (2-tailed)		.000
	N	402	389
R_Hemoglobin	Pearson Correlation	-.192[a]	1.000
	Sig. (2-tailed)	.000	
	N	389	390

a. Significant at .05 level

Рисунок 4 - Результати розрахунку коефіцієнта кореляції Спірмена через рангові змінні

Аналіз одержаних результатів

Показник	Результат
Метод аналізу	рангова кореляція Спірмена
Змінні	Lipoproteins та Hemoglobin
Коефіцієнт кореляції	r = -0,192
Значущість	p = 0,000
Кількість парних спостережень	N = 389
Тип зв’язку	зворотний
Тіснота зв’язку	слабкий негативний зв’язок

Отримане значення коефіцієнта кореляції становить r = -0,192. Оскільки коефіцієнт має від’ємний знак, між змінними існує зворотний зв’язок: зі збільшенням однієї змінної інша має слабку тенденцію до зменшення.

За шкалою оцінювання тісноти кореляційного зв’язку значення від 0,00 до -0,24 відповідає слабкому негативному зв’язку. Значення p = 0,000 є меншим за 0,01, тому кореляція статистично значуща.

Висновок до практичного завдання

У ході практичного заняття було виконано кореляційний аналіз між змінними Lipoproteins та Hemoglobin. Спочатку було підготовлено та імпортовано дані в PSPP, після чого побудовано діаграму розсіювання для попередньої оцінки залежності.

За критерієм Колмогорова-Смірнова встановлено, що розподіл даних не є нормальним, тому для оцінювання взаємозв’язку було обрано коефіцієнт рангової кореляції Спірмена. Отримано r = -0,192 при p = 0,000 і N = 389. Це свідчить про слабкий зворотний статистично значущий зв’язок між ліпопротеїнами та гемоглобіном.

Питання для самоконтролю

1. Які задачі вирішує кореляційний аналіз?

Кореляційний аналіз вирішує задачі вимірювання сили зв’язку між ознаками, визначення напряму залежності, відбору факторів, що найбільше впливають на результативну ознаку, а також виявлення можливих причинних зв’язків.

2. Як знайти коефіцієнт кореляції?

Спочатку потрібно визначити тип даних і перевірити нормальність розподілу. Якщо дані кількісні та мають нормальний розподіл, застосовують коефіцієнт Пірсона. Якщо розподіл не нормальний або дані рангові, використовують коефіцієнт Спірмена. Після розрахунку аналізують знак, модуль коефіцієнта та p-значення.

3. Які типи коефіцієнтів кореляції існують?

Найпоширенішими є коефіцієнт кореляції Пірсона, ранговий коефіцієнт кореляції Спірмена та коефіцієнт Кендалла. Пірсона використовують для кількісних нормально розподілених даних, а Спірмена і Кендалла - для рангових або ненормально розподілених даних.

4. В чому відмінність між прямою та зворотною кореляцією?

Пряма кореляція означає, що зі збільшенням однієї змінної інша також має тенденцію до збільшення. Зворотна кореляція означає, що зі збільшенням однієї змінної інша має тенденцію до зменшення.

5. Як проаналізувати значення коефіцієнта кореляції на значимість?

Значущість коефіцієнта кореляції оцінюють за p-значенням. Нульова гіпотеза H0 стверджує, що кореляції в генеральній сукупності немає. Якщо p менше обраного рівня значущості, наприклад 0,05 або 0,01, нульову гіпотезу відхиляють і роблять висновок, що кореляція статистично значуща.

Загальний висновок

Практичне заняття виконано повністю. Було опрацьовано основні етапи кореляційного аналізу: підготовка даних, побудова діаграми розсіювання, перевірка нормальності розподілу, вибір методу кореляції, розрахунок коефіцієнта та інтерпретація результатів. Отриманий результат підтверджує наявність слабкого зворотного статистично значущого зв’язку між змінними Lipoproteins та Hemoglobin.